

Módulo Python for Analytics – Sesión 01

Diploma Data Scientist

Docente: Geider Nuñuvero



PERFIL PROFESIONAL



Educación:

- UNIVERSIDAD NACIONAL DE INGENIERIA : Ingeniero Estadístico
- edX MITx : MicroMasters Program Statistics and Data Science
- UDACITY : Machine Learning Engineer Nanodegree Program

Experiencia Laboral:

- Analytics Product Manager : Backus
- Lead Data Scientist: Interbank
- Consultor Senior en Data Science: Tottus y entidades públicas
- Senior Project Lead in Data Science : Rimac Seguros
- Sr Data Scientist : Belcorp
- Analista de Data Mining: Telefónica Ingeniería de Seguridad



REGLAS



Se requiere **puntualidad** para un mejor desarrollo del curso.



Para una mayor concentración **mantener silenciado el micrófono** durante la sesión.



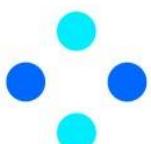
Las preguntas se realizarán **a través del chat** y en caso de que lo requieran **podrán activar el micrófono**.



Realizar las actividades y/o tareas encomendadas en **los plazos determinados**.



Identificarse en la sala Zoom con el primer nombre y primer apellido.



Objetivo

Este curso busca **enseñar los fundamentos de Python** para el análisis de datos, incluyendo la instalación de entornos, manejo de estructuras de datos y el uso de la librería Pandas para manipulación y análisis eficiente de datos

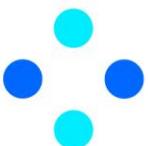
Silabo

- Introducción a Python.
- Instalación (descriptivo) , ambientes y librerías.
- Variables y tipos de datos.
- Estructuras de datos (Listas, tablas, diccionarios).
- Estructuras de control (Indentación, condicionales y bucles).
- Manipulación de datos (Librería Pandas).



¿Qué es Analytics?

- **Analytics** puede ser definido como el proceso que abarca el uso de técnicas estadísticas, sistemas de información e investigación de operaciones para explorar, visualizar, descubrir; y comunicar patrones y tendencias en la data.
- **Analytics** puede convertir data en información útil, transformándola en un activo para las empresas.
- En pocas palabras, la **analytics** nos ayuda a ver información y datos significativos que de otro modo no podríamos detectar.
- La **analítica empresarial** se centra en el uso de conocimientos derivados de los datos para **tomar decisiones** más informadas que ayudarán a las organizaciones a aumentar las ventas, reducir los costes y realizar otras mejoras comerciales.



Niveles de Analytics



Importancia de tener un proyecto de Analytics



Mejor entendimiento del cliente.

- Lealtad, ciclo de vida, perfiles, comportamientos, ...
- Mercado Saturado.

Estrategia efectiva en la toma de las decisiones.

- Rápida y de gran conocimiento.
- Memoria Inteligente.
- Más allá que aplicación de modelos.
- Conocimiento del negocio aplicado a los modelos.
- Resultados confiables, accionables y repetibles.



¿Qué es Python?

Python es un lenguaje de programación de alto nivel, de código abierto ampliamente usado en la actualidad debido a su versatilidad, simplicidad y popularidad en diversas aplicaciones.



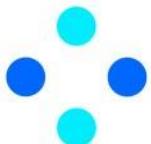
Veamos algunas de las características que lo hacen famoso

Lenguaje interpretado



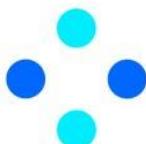
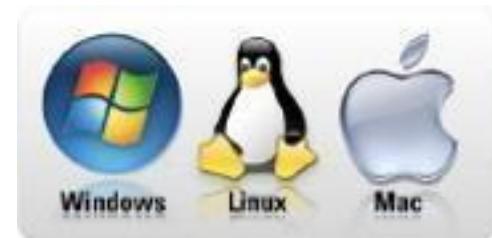
Python es un lenguaje interpretado, cada vez que se ejecuta una línea se ejecuta el código, dando un resultado

Lenguaje compilado



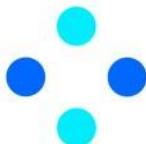
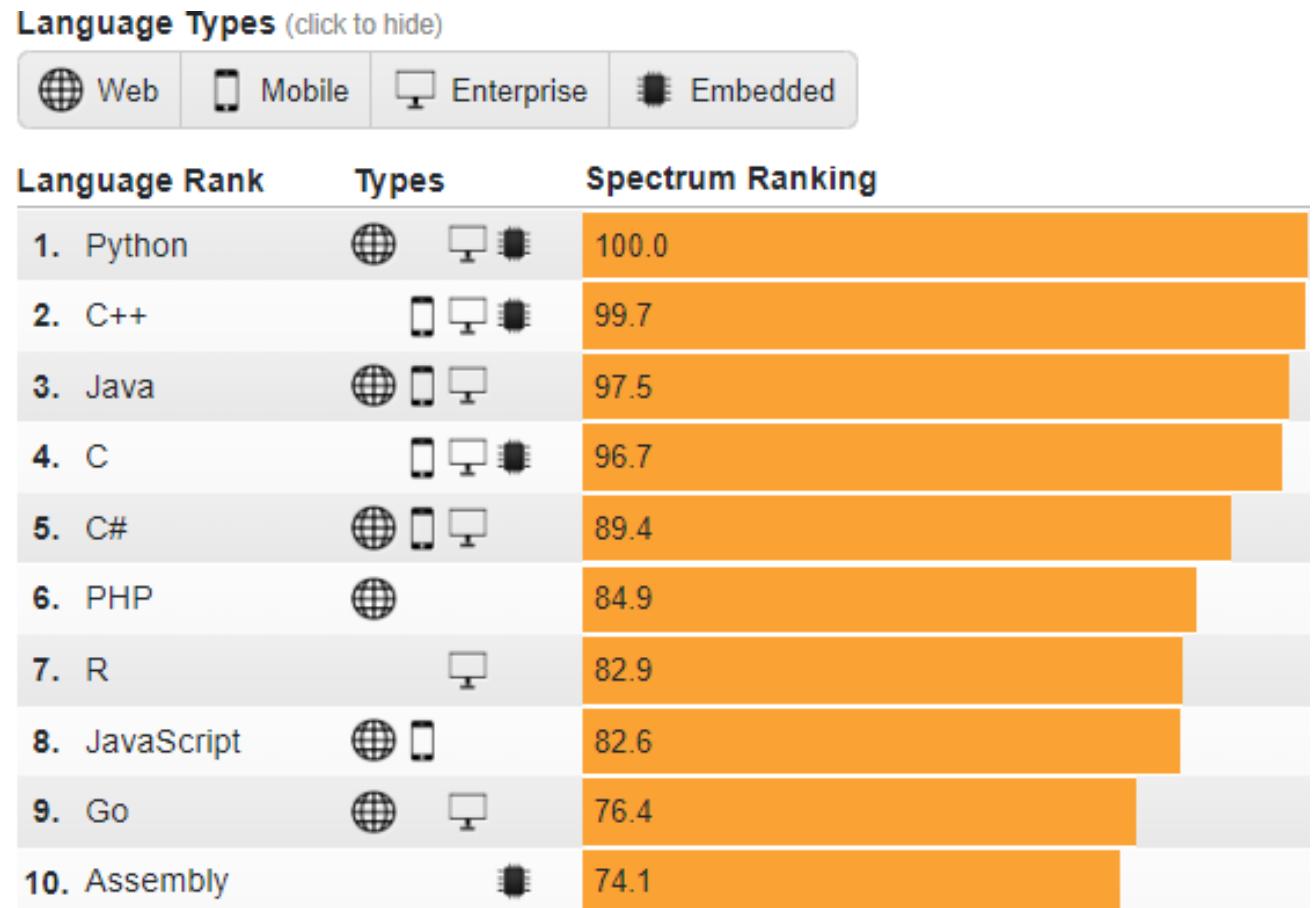
¿Por qué Python?

- ✓ Es un lenguaje de programación interpretado. ¡Bye compilador!
- ✓ Posee un tipado dinámico, es decir no requiere que se declare el tipo de dato de cada variable creada y además puede cambiar conforme se le vaya asignando valores.
- ✓ Recomendado para aprender el programa, sintaxis muy sencilla y legible (como si estuviéramos hablándole al ordenador)
- ✓ ¡Código abierto! Completamente gratis, libre de usar y distribuir sin perder presencia en ámbitos comerciales.
- ✓ Es multiplataforma, se puede utilizar y ejecutar en Windows, Linux, Mac, etc.
- ✓ Enorme cantidad de módulos y paquetes respaldados por la comunidad .



Ventajas de Python sobre otros lenguajes

- ✓ IEEE Spectrum, la organización profesional más grande del mundo dedicada a la ingeniería y las ciencias aplicadas, elabora anualmente un ranking de los lenguajes de programación más usados, preferidos y relevantes, que este año ubicó a Python en el primer lugar.



Ventajas de Python sobre otros lenguajes

1. Está desarrollado bajo una licencia de código abierto, por lo que es de libre uso y distribución, incluso para uso comercial.
2. Es uno de los lenguajes de programación más versátiles que existen, puede ser usado en muchos campos diferentes. Es decir, permite programar desde videojuegos hasta aplicaciones móviles.
3. Es fácil de aprender. Si comprendes Python, podrás entender más fácilmente otros lenguajes de programación. Esto quiere decir que es una excelente opción si apenas incursionas en el mundo de los desarrolladores.
4. Gracias a su popularidad, cuenta con una amplia comunidad que organiza eventos, conferencias, reuniones y colabora en materia de códigos e información.
5. El Python Package Index (PyPI) aloja miles de módulos de terceros para Python. Tanto la biblioteca estándar de Python como los módulos aportados por la comunidad permiten infinitas posibilidades.



¿Quiénes utilizan Python?



- Google & YouTube.
- Instagram desarrollado en Django (framework de Python).
- Recomendación de series y películas en Netflix.
- Casi la cuarta parte de Facebook está escrito en Python.



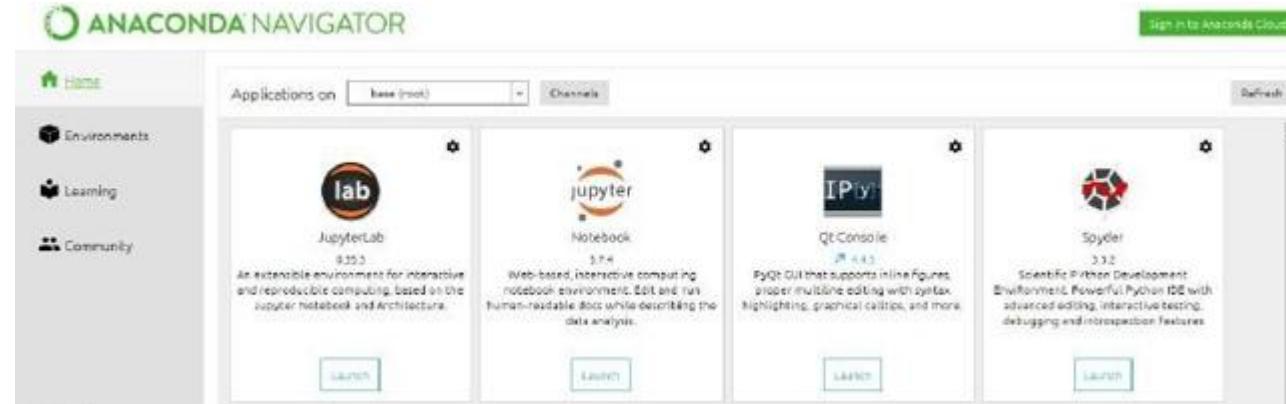
Proceso de instalación Python con Jupyter

1. Descargar Anaconda (<https://www.anaconda.com/download/success#download>) desde la página oficial, selecciona la versión para Windows (64-bit).
2. Ejecutar el instalador y aceptar términos.
3. Elegir instalación 'Just Me' y ruta por defecto.
4. No agregar Anaconda al PATH.
5. Registrar Anaconda como Python por defecto
6. Finalizar e iniciar Anaconda Navigator.

Software y editores de código para ciencia de datos

Elegir el computador y editor de código a utilizar:

- ✓ Kernel de Anaconda (requiere instalación en propia PC) y utilizar un editor de los tantos que ofrece (Visual Studio Code, Jupyter Notebook, Spyder, etc.).
- ✓ Utilizar una solución en la nube que provea el computador y/o editor de código como Google Colab (.ipynb).



ANACONDA NAVIGATOR

[Upgrade Now](#)[Sign in to Anaconda Cloud](#)[Home](#)[Environments](#)[Learning](#)[Community](#)[Documentation](#)[Developer Blog](#)[Feedback](#)

Applications on

base (root)

Channels

Refresh

**jupyterlab**
0.31.12

An extensible environment for interactive and reproducible computing, based on the Jupyter Notebook and Architecture.

[Launch](#)**jupyter notebook**
5.4.0

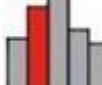
Web-based, interactive computing notebook environment. Edit and run human-readable docs while describing the data analysis.

[Launch](#)**qtconsole**
4.3.1

PyQt GUI that supports inline figures, proper multiline editing with syntax highlighting, graphical calltips, and more.

[Launch](#)**spyder**
3.3.0

Scientific PYTHON Development EnvIRonment. Powerful Python IDE with advanced editing, interactive testing, debugging and introspection features

**glueviz**
0.13.3

Multidimensional data visualization across files. Explore relationships within and among related datasets.

**orange3**
3.13.0

Component based data mining framework. Data visualization and data analysis for novice and expert. Interactive workflows with a large toolbox.



Jupyter Notebook



```
jupyter covid_19_dashboard Last Checkpoint: Last Friday at 11:45 PM (unsaved changes) ✓
File Edit View Insert Cell Kernel Widgets Help
Trusted Python 3 Logout
In [13]: # importing libraries
from __future__ import print_function
from ipywidgets import interact, interactive, fixed, interact_manual
from IPython.core.display import display, HTML

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import plotly.express as px
import folium
import plotly.graph_objects as go
import seaborn as sns
import ipywidgets as widgets

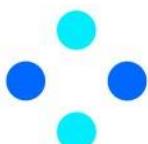
In [14]: # loading data right from the source:
death_df = pd.read_csv('https://raw.githubusercontent.com/CSSEGISandData/COVID-19/master/csse_covid_19_data/csse_covid_
confirmed_df = pd.read_csv('https://raw.githubusercontent.com/CSSEGISandData/COVID-19/master/csse_covid_19_data/csse_covid_
recovered_df = pd.read_csv('https://raw.githubusercontent.com/CSSEGISandData/COVID-19/master/csse_covid_19_data/csse_covid_
country_df = pd.read_csv('https://raw.githubusercontent.com/CSSEGISandData/COVID-19/web-data/data/cases_country.csv')

In [15]: confirmed_df.head()

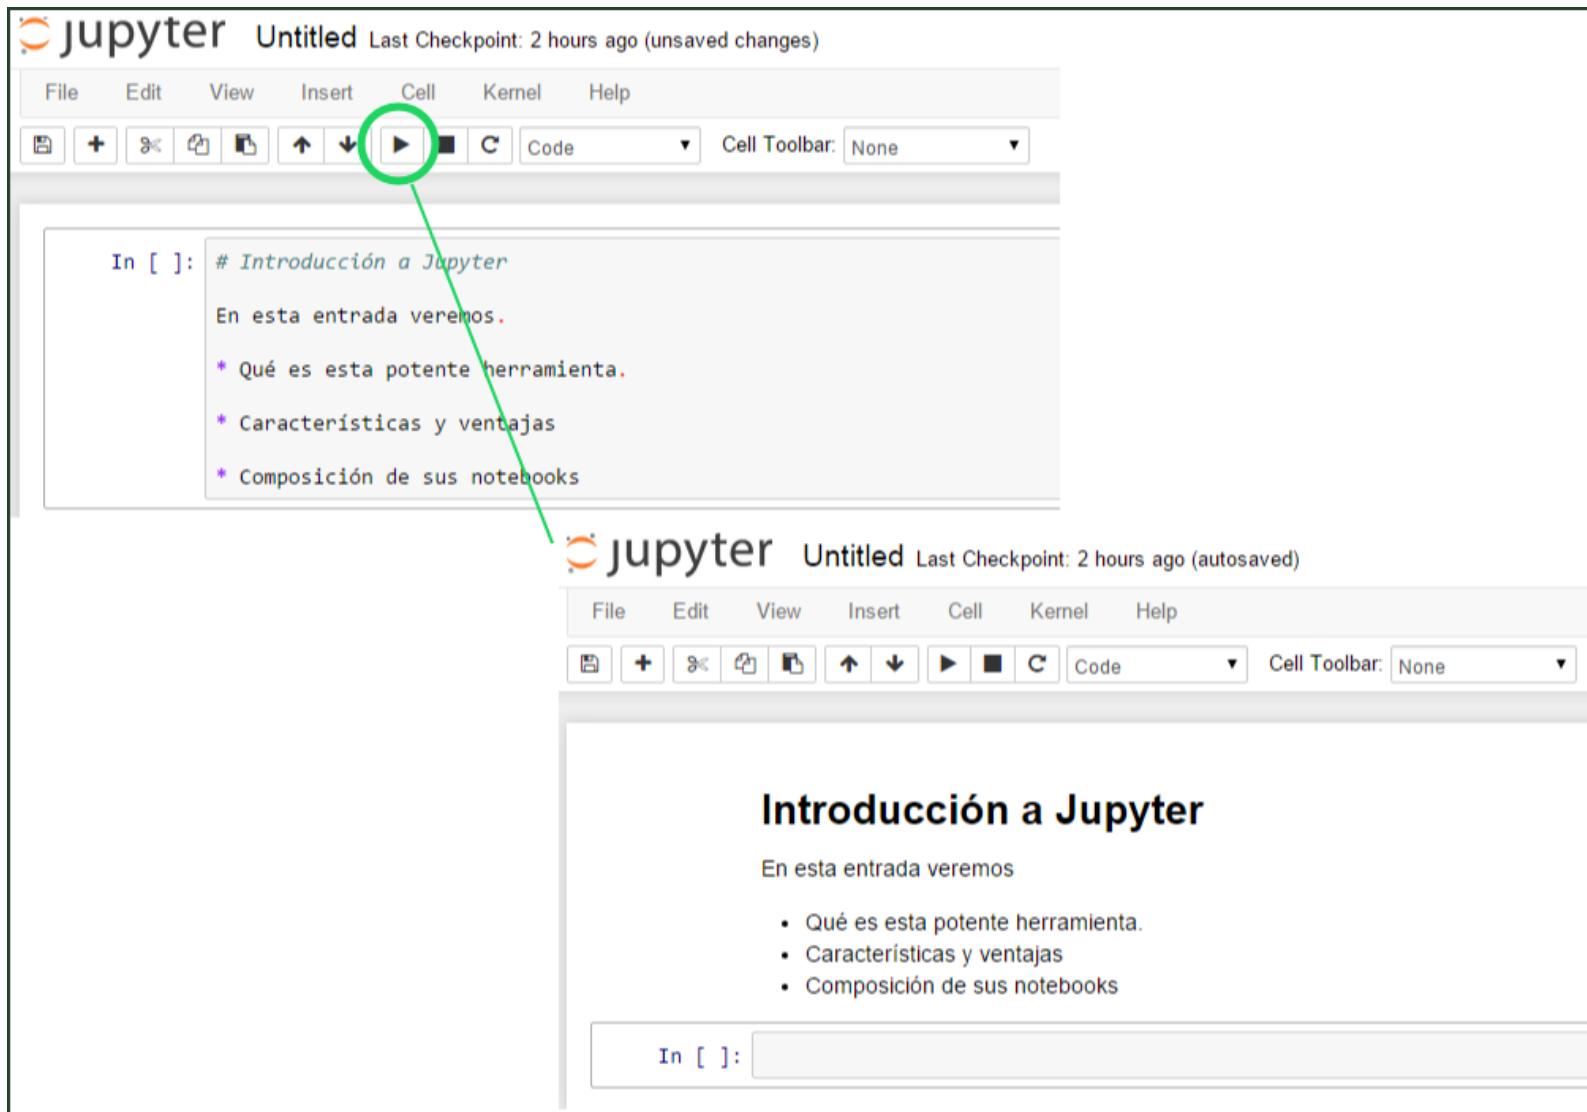
In [16]: recovered_df.head()

In [17]: death_df.head()

In [18]: country_df.head()
```



Jupyter Notebook



The image shows a Jupyter Notebook interface with two cells. The top cell is an input cell containing the following code:

```
In [ ]: # Introducción a Jupyter  
En esta entrada veremos.  
* Qué es esta potente herramienta.  
* Características y ventajas  
* Composición de sus notebooks
```

A green arrow points from the right side of this cell to the output cell below. The output cell is a rendered text cell displaying the same content:

Introducción a Jupyter

En esta entrada veremos

- Qué es esta potente herramienta.
- Características y ventajas
- Composición de sus notebooks

In []:



Jupyter Notebook

jupyter Untitled

Logout

File Edit View Insert Cell Kernel Widgets Help Trusted Python 3 O

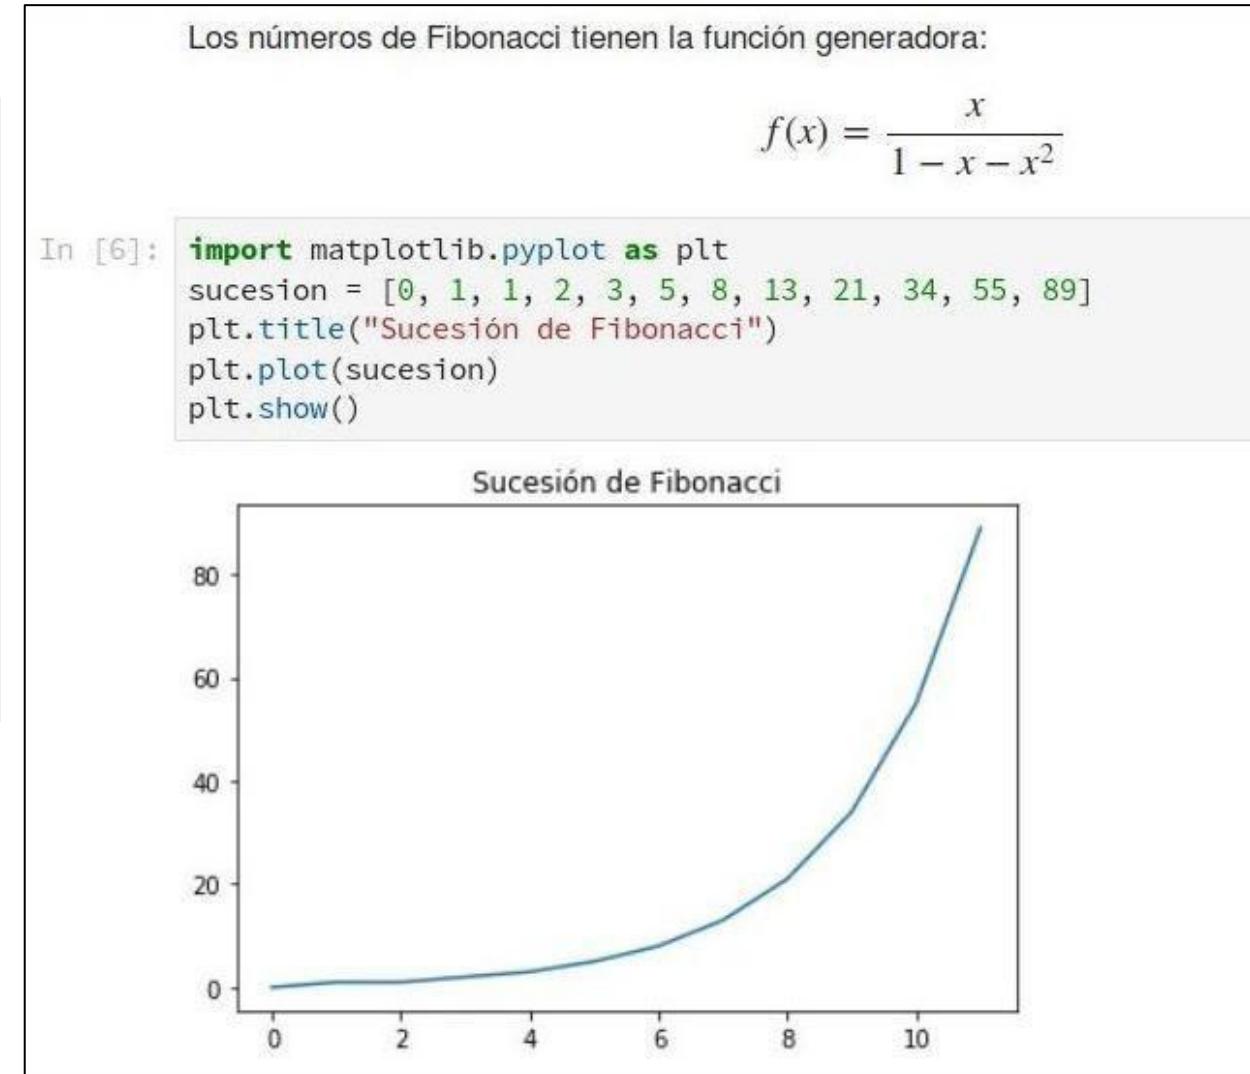
Code

Este es un ejemplo de una celda de Markdown

Al oprimir Enter, podremos editar el contenido de esta celda

In [1]: `# Este es el ejemplo de una celda de código
print("Las celdas de código se pueden ejecutar")`

Las celdas de código se pueden ejecutar

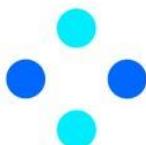


Google Colab



Es la solución de Google para el desarrollo de proyectos de Ciencia de Datos alojados completamente en la Nube, entre sus ventajas tenemos:

- ✓ Brinda una máquina virtual con 13 gb de ram y 50 gb de disco.
- ✓ Es completamente gratuito aunque pronto habrá una versión de pago.
- ✓ Se sincroniza con nuestros archivos de Google Drive y nuestros notebooks se guardan automáticamente en una carpeta llamada Colab Notebooks.



Principales librerías o módulos en Python

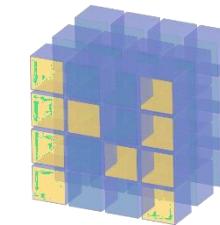


Principales librerías o módulos en Python

NumPy: el nombre viene de numerical Python, Es una de las librerías más útiles en Python para el cálculo matricial, implementando una gran diversidad de funciones y transformaciones algébricas.

SciPy: el nombre corresponde a la expresión Scientific Python. SciPy evoluciona las funciones de NumPy añadiendo, por ejemplo la posibilidad de calcular series de Fourier y ejecutar procesos de optimización.además facilita trabajar con matrices dispersas.

Pandas: se trata una de las librerías estrella de Python, Agrupa una serie de funcionalidades clave que facilita el siempre indispensable y engorroso trabajo de limpiar, formatear y procesar adecuadamente los datos.



NumPy



SciPy

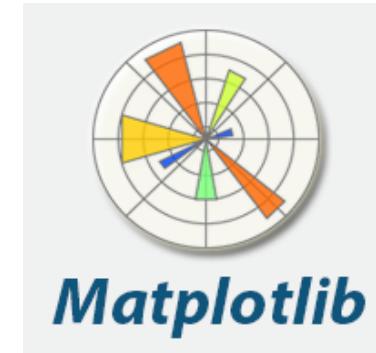


pandas



Principales librerías o módulos en Python

Matplotlib: indispensable a la hora de generar gráficos que nos ayuden a comprender mejor las características de nuestros datos, análisis y modelos.



Sckit Learn for Machine Learning: partiendo de la base de las funcionalidades ofrecidas por NumPy, SciPy y Matplotlib, ofrece utilidades que permite ejecutar de forma sencilla algoritmos de aprendizaje automático y modelos estadísticos, incluyendo regresión, clasificación, clustering y reducción de dimensiones.



Statsmodels: librería enfocada en el modelo estadístico, La exploración de los datos, creación de modelos estadísticos y realización de test estadísticos es el objetivo de esta librería. StatsModels proporciona un listado considerable de estimadores estadísticos complementados con funcionalidades para la visualización del trabajo realizado.



Principales librerías o módulos en Python

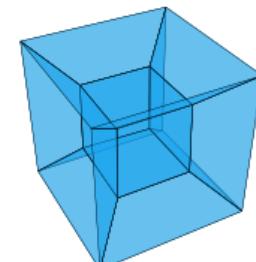
Seaborn: extraordinaria librería de visualización basada en Matplotlib. El objetivo de Seaborn es ayudar a las tareas de exploración de los datos, proporciona amplia y diversa información estadística de forma gráfica, lo que facilita su comprensión.



Bokeh: librería que ofrece gráficos iterativos y dinámicos. Bokeh es una librería eficiente que facilita la creación de cuadros de mando visualmente atractivos.



Blaze: esta librería parte de la base proporcionada tanto por NumPy como Pandas para facilitar el tratamiento de datos distribuidos y generados de forma continua (streaming). Permite acceder a bases de datos en distintas ubicaciones y repositorios variados como bases de datos NoSQL o ficheros de archivos distribuidos. Blaze proporciona herramientas para la visualización de datos en este contexto.



Blaze



Software y componentes utilizados en la industria para machine learning (ML)

Plataforma	Enfoque	Lo más destacado	Ecosistema / Integración
 Azure Machine Learning	ML end-to-end + MLOps	AutoML, notebooks, pipelines, generación IA	Azure completo: redes, seguridad, CI/CD
	ML en nube robusta	ML incorporado, frameworks gestionados + integración AWS	Amplia integración con servicios AWS
	ML + Generative AI	Gemini, AutoML, Agent Builder, vídeo generativo	Modelos Google, infraestructura GCP
	DL + Big Data + ML	Lakehouse, Spark, MLflow, LLM propio, Mosaic AI	Multi-nube, fuerte para data engineering + ML
	Analítica avanzada ML	Automatización, interpretabilidad, módulos sectoriales	Multi-nube, fuerte en gobernanza y cumplimiento

¡MUCHAS GRACIAS!

