

MACHINE LEARNING

Métodos No Supervisados

SESIÓN I

Docente: César Quezada



PERFIL PROFESIONAL



Científico de Datos Sr.
Clínica Internacional

César Manuel Quezada Balcazar

- ✓ + 13 años de experiencia en proyectos de inteligencia artificial en la industria de Marketing, Investigación, Telecomunicaciones y Agro
- ✓ Ingeniería de datos - SDC
- ✓ Machine Learning - Stanford University.
- ✓ Big Data Science - DMC
- ✓ Gestión de proyectos - UTP
- ✓ Ingeniero Estadístico - UNI.



César Quezada



Me puedes encontrar como:



cesarmqb@gmail.com



[\[www.linkedin.com/in/cquezadab\]](https://www.linkedin.com/in/cquezadab)



[\[https://cesarquezadab.com\]](https://cesarquezadab.com)



[\[Data-Science-Files\]](#)



[\[https://github.com/cesarqb\]](https://github.com/cesarqb)




[\[cesar.quezada19\]](#)

AGENDA:

1. Métodos No Supervisados
2. Metodología de estudio
3. Clasificación de métodos No Supervisados
4. Caso Práctico
 - Segmentación K-means





SUPERVISED LEARNING

TYPE OF ML	ALGORITHM	USE	ALGORITHM DESCRIPTION	EVALUATION METRICS
	Linear Regression	Regression	Predicts values by drawing a regression line through the middle of the data points	• Mean Squared Error (MSE) • R-Squared
	Logistic Regression	Classification	Translates values to a binary category (0 or 1) using a logistic function	• Accuracy • Precision • Recall • F1 S
	Decision Trees	• Classification • Regression	Uses the hierarchical (tree) structure to predict values	• Classification • Accuracy • Precision • Recall • F1 score • Regression • MSE • R-squared
	Naive Bayes	Classification	Uses the Bayes' theorem for data classification	• Accuracy • Precision • Recall • F1 S
	K-Nearest Neighbors (KNN)	• Classification • Regression	Predicts value by calculating the distance between the data point and the k-number of their nearest neighbors	• Classification • Accuracy • Precision • Recall • F1 score • Regression • MSE • R-squared

SUPERVISED LEARNING

	K-Nearest Neighbors (KNN)	• Classification • Regression	Predicts value by calculating the distance between the data point and the k-number of their nearest neighbors	• Classification • Accuracy • Precision • Recall • F1 score • Regression • MSE • R-squared
	Support Vector Machines (SVM)	• Classification • Regression	Draws a hyperplane that maximizes the distance between the classes or predicted and actual values	• Classification • Accuracy • Precision • Recall • F1 score • Regression • MSE • R-squared
	Random Forest	• Classification • Regression	Makes predictions based on an ensemble of decision trees	• Classification • Accuracy • Precision • Recall • F1 score • Regression • MSE • R-squared
	Gradient Boosting	• Classification • Regression	Makes predictions based on predictions of the ensemble of weak models that correct each other's mistakes	• Classification • Accuracy • Precision • Recall • F1 score • Regression • MSE • R-squared
	K-Means Clustering	Clustering	Divides data into the k-number of clusters based on its geometric center	• Inertia • Silhouette Score
UNSUPERVISED LEARNING	Principal Component Analytics (PCA)	Dimensionality Reduction	Reduces the number of variables while capturing the majority of data variance	• Explained Variance • Total Explained Variance

Aprendizaje No Supervisado



MODELOS NO SUPERVISADOS

Ejemplos de aplicación de clustering

- Dado un conjunto de clientes, encontrar segmentos de mercado para aplicar estrategias de comunicación diferenciadas
- Dado un conjunto de noticias, identificar tópicos de información y agruparlas por su contenido
- Dentro de un conjunto de correos, identificar aquellos relacionados a spam o correos no deseados



Segmentación de clientes



MODELOS NO SUPERVISADOS

Ejemplos de aplicación de clustering

SEGMENTACIÓN DE COCA COLA



MODELOS NO SUPERVISADOS

La segmentación de mercado de Coca-Cola es un ejemplo clásico de cómo una marca global puede adaptar su estrategia de marketing para satisfacer diferentes necesidades y preferencias de los consumidores en todo el mundo

Geográfica:

Coca-Cola adapta sus productos y campañas publicitarias según la región o el país. Esto puede incluir el lanzamiento de sabores específicos que se adapten a los gustos locales, así como el ajuste de las estrategias de marketing para alinearse con las costumbres y culturas locales.

Psicográfica:

Esta segmentación se basa en el estilo de vida, los valores, la personalidad y los intereses de los consumidores. Coca-Cola a menudo se asocia con un estilo de vida activo y social, y sus campañas de marketing suelen resaltar estos valores.

Demográfica:


La segmentación demográfica incluye variables como la edad, el género, el ingreso, el nivel educativo y el tamaño de la familia. Por ejemplo, Coca-Cola puede enfocar ciertas bebidas hacia un público más joven, mientras que otras pueden estar dirigidas a personas de mayor edad.

Segmentación por beneficios:

Coca-Cola también considera los beneficios que buscan los consumidores en sus productos, como el sabor, la conveniencia, la salud y la hidratación. Por ejemplo, lanzan versiones como Coca-Cola Zero para aquellos que buscan una opción sin azúcar.

MODELOS NO SUPERVISADOS

Ejemplos de aplicación de clustering



Aprendizaje: no supervisado



Características

Aprendizaje
no
supervisado

Dataset de Entrenamiento


		Predictores (Features)				
		x_1	x_2		x_p	
Muestras	1					
	n					

n muestras de
entrenamiento
o instancias

p
predictores

Resolución de problemas:

- Clustering
- Reducción de dimensionalidad.
- Detection de anomalías.



Datos Transformados y
Agrupados en Clústeres

No tenemos etiquetas
en los datos (Y)

Pizarra 1


Características

Pizarra 2


- ✓ En el **Aprendizaje NO Supervisado**, los datos de entrenamiento no están etiquetados con una **salida Y** (variable objetivo, target, etc.).
- ✓ A diferencia del aprendizaje supervisado, en el no supervisado **no hay forma determinística de verificar el performance del modelo**. Sólo se puede evaluar con conocimiento del negocio.
- ✓ Algunas aplicaciones típicas del aprendizaje no supervisado son:
 - Segmentación de clientes.
 - Detección de fraude o anomalías.
- ✓ Otra aplicación importante es la **reducción de dimensionalidad**.




Clasificación de métodos No Supervisados



TIPOS DE CLUSTER



Metodología




Segmentación K-Means



K-means

- ✓ En K-means el objetivo es agrupar las observaciones de un dataset en un número K de clústeres.
- ✓ En número K es **hiperparámetro** que hay que darle al algoritmo.

Ejemplo: para el caso de dos predictores para distintos valores de K



K-means

Pizarra 3

- ✓ Al igual que el caso del PCA, las variables predictoras deben ser normalizadas antes de hacer el clustering.
- ✓ Los atributos han de ser numéricos (pues se computa la media de los mismos para reasignar los centroides).
- ✓ El **método de la silueta** suele ser un indicador para medir cómo de bien una observación se adapta a su cluster.
- ✓ Es muy sensible a los valores anómalo (outliers).




K-means

El algoritmo K-means se explica de la siguiente manera:

- ✓ De manera aleatoria asignar un número de 1 a K a cada observación. Esto será la asignación inicial a los clústeres de cada observación.
- ✓ Iterar sobre los siguientes pasos hasta que las asignaciones a los clústeres deje de cambiar:
 - a. Para cada clúster, calcule el centroide será un vector compuesto por la media de los p predictores de las observaciones del mismo cluster.
 - b. Reasigne cada observación al clúster cuyo centroide esté más cercano a la observación.



El siguiente gráfico ilustra el algoritmo K-means:



REFERENCIAS

- “Three ways to detect outliers” (Blog)
 - <http://colingorrie.github.io/outlier-detection.html>
- Anomaly detection with Local Outlier Factor (LOF)
 - http://scikit-learn.org/stable/auto_examples/neighbors/plot_lof.html
- How to Identify Outliers in your Data (Blog)
 - <https://machinelearningmastery.com/how-to-identify-outliers-in-your-data/>



¡GRACIAS!

