

MACHINE LEARNING

Métodos No Supervisados

SESIÓN III

Docente: César Quezada



PERFIL PROFESIONAL



Científico de Datos Sr.
Clínica Internacional

César Manuel Quezada Balcazar

- ✓ + 13 años de experiencia en proyectos de inteligencia artificial en la industria de Marketing, Investigación, Telecomunicaciones y Agro
- ✓ Ingeniería de datos - SDC
- ✓ Machine Learning - Stanford University.
- ✓ Big Data Science - DMC
- ✓ Gestión de proyectos - UTP
- ✓ Ingeniero Estadístico - UNI.



César Quezada



Me puedes encontrar como:



cesarmqb@gmail.com



[\[www.linkedin.com/in/cquezadab\]](https://www.linkedin.com/in/cquezadab)



[\[https://cesarquezadab.com\]](https://cesarquezadab.com)



[\[Data-Science-Files\]](#)



[\[https://github.com/cesarqb\]](https://github.com/cesarqb)



[\[cesar.quezada19\]](#)


AGENDA

1. Reducción de Dimensionalidad

2. Análisis de Componente Principal


- Metodología
- PCA
- Perfil y Visualización
- Caso práctico real

Reducción de Dimensionalidad




6 VARIABLES

- Ojo derecho
- Ojo izquierdo
- Nariz completa
- Boca completa
- Oreja derecho
- Oreja izquierda




6 VARIABLES

- Ojo derecho
- Ojo izquierdo
- Nariz completa
- Boca completa
- Oreja derecho
- Oreja izquierda




4 VARIABLES

- Ojo izquierdo
- Nariz media
- Boca media
- Oreja izquierda




6 VARIABLES

- Ojo derecho
- Ojo izquierdo
- Nariz completa
- Boca completa
- Oreja derecho
- Oreja izquierda



4 VARIABLES


- Ojo izquierdo
- Nariz media
- Boca media
- Oreja izquierda



Podemos Identificar a la
imagen original

¿Qué es el análisis de componentes principales (PCA)?

El análisis de componentes principales, o PCA, reduce el número de dimensiones en grandes conjuntos de datos a componentes principales que conservan la mayor parte de la información original. Para ello, transforma las variables potencialmente correlacionadas en un conjunto más pequeño de variables, denominadas componentes principales.



PCA para Reducción de dimensiones

PCA

¿No sería mejor tomar menos variables, pero más valiosas?

Técnica de Extracción de Características donde combinamos las entradas de una manera específica y podemos eliminar algunas de las variables “menos importantes” manteniendo la parte más importante todas las variables. Como valor añadido, luego de aplicar PCA conseguiremos que todas las nuevas variables sean independientes una de otra.

En el PCA se calculan dos componentes principales: el primer componente principal (PC1) y el segundo componente principal (PC2).


Primer componente principal

El primer componente principal (PC1) es la dirección en el espacio a lo largo de la cual los puntos de datos tienen la mayor o mayor varianza. Es la línea que mejor representa la forma de los puntos proyectados. Cuanto mayor sea la variabilidad captada en el primer componente, mayor será la información retenida del conjunto de datos original. Ningún otro componente principal puede tener una variabilidad mayor.

Segundo componente principal

Calculamos el segundo componente principal (PC2) de la misma manera que el PC1. El PC2 representa la siguiente varianza más alta en el conjunto de datos y no debe estar correlacionada con el PC1. Es decir, el PC2 debe ser ortogonal, es decir, perpendicular, al PC1. Esta relación también se puede expresar como la correlación entre el PC1 y el PC2 igual a cero.

Normalmente se utiliza un diagrama de dispersión para mostrar la relación entre el PC1 y el PC2 cuando se aplica el PCA a un conjunto de datos. Los ejes PC1 y PC2 serán perpendiculares entre sí.



ENTENDIENDO EL PCA

Supongamos que jugamos a las adivinanzas con nuestros amigos. El juego es sencillo. Nuestros amigos se cubrirían la cara y tendríamos que adivinar quién es quién basándonos únicamente en su altura. Como buenos amigos que somos, recordamos la altura de cada uno.



A



B



C

Person	Height (cm)
Alex	145
Ben	160
Chris	185

ENTENDIENDO EL PCA

Ahora, intentemos adivinar un grupo diferente de amigos.



A



B



C

Person	Height (cm)
Daniel	172
Elsa	173
Fernandez	171

ENTENDIENDO EL PCA

De la misma manera, cuando nuestros datos tienen una mayor varianza, contienen más información. Por eso siempre escuchamos PCA y varianza máxima en la misma oración. Me gustaría formalizar esto citando un fragmento de Wikipedia.

PCA se define como una transformación lineal ortogonal que transforma los datos a un nuevo sistema de coordenadas de modo que la **mayor varianza** según alguna proyección escalar de los datos se encuentre en la primera coordenada (llamada primer componente principal), la segunda mayor varianza en la segunda coordenada, y así sucesivamente.

A los ojos del PCA, la varianza es una forma objetiva y matemática de cuantificar la cantidad de información en nuestros datos.


La varianza es información.

ENTENDIENDO EL PCA

Para dejar esto en claro, propongo una revancha del juego de adivinanzas, solo que esta vez, podremos adivinar quién es quién en función de su altura y peso.

Person	Height (cm)	Weight (kg)
Alex	145	68
Ben	160	67
Chris	185	69

Estas dos nuevas variables se denominan primer componente principal (PC1) y segundo componente principal (PC2) . En lugar de usar la altura y el peso en ambos ejes, podemos usar PC1 y PC2 respectivamente.




PCA vs. LDA vs. análisis factorial

El PCA es una técnica de reducción de dimensiones como [el análisis discriminante lineal](#) (LDA). A diferencia del LDA, el PCA no se limita a tareas de [aprendizaje supervisado](#). Para las tareas de [aprendizaje no supervisado](#), esto significa que el PCA puede reducir las dimensiones sin tener que considerar etiquetas de clase o categorías. El PCA también está estrechamente relacionado con el análisis factorial. Ambos reducen el número de dimensiones o variables de un conjunto de datos y, al mismo tiempo, minimizan la pérdida de información. El PCA divide las variables en un subconjunto de componentes principales linealmente independientes. Sin embargo, el análisis factorial se utiliza generalmente para entender las estructuras de datos subyacentes y se centra en las variables latentes o en los factores no medidos que capturan el diferencial de una variable.

Características


- ✓ Procedimiento matemático que reduce un conjunto de variables posiblemente correlacionadas a un conjunto de variables no correlacionadas.
- ✓ El objetivo es obtener un conjunto de variables que expliquen la mayor variabilidad posible de las variables originales.
- ✓ Es una técnica solo aplicable para variables numéricas.
- ✓ Sensible a la escala de las variables (transformación para homologar sus dimensiones)



Saigayatri Vadali , ene-18


Interpretación

- ✓ Dirección de vectores: Indica donde influye la variable.
- ✓ Longitud del vector: Mide la importancia de la variable en la componente.
- ✓ Posición de elementos: Si está ubicado en la dirección del vector tiene valor alto en esa variable.



Metodología

Proceso de Segmentación



Retroalimentación

¡GRACIAS!

