

# Dip. Data Science

## Curso:

# Estadística Descriptiva

**Sesión 03**

**Docente: Nilton Yanac**  
**Enero, 2026**



## REGLAS



Se requiere **puntualidad** para un mejor desarrollo del curso.



Para una mayor concentración **mantener silenciado el micrófono** durante la sesión.



Las preguntas se realizarán **a través del chat** y en caso de que lo requieran **podrán activar el micrófono**.



Realizar las actividades y/o tareas encomendadas en **los plazos determinados**.



**Identificarse** en la sala Zoom con el primer nombre y primer apellido.



## ITINERARIO

*07:00 PM – 07:30 PM      **Soporte técnico DMC***

*07:30 PM – 08:50 PM      **Agenda***

*08:50 PM – 09:00 PM      **Pausa Activa***

*09:00 PM – 10:30 PM      **Agenda***

*Horario de Atención Área Académica y Soporte*

*Lunes a Viernes 09:00 am a 10:30 pm / Sábado 09:00 am a 02:00pm*



# SILABO

## **Objetivo del curso:**

*Conocer las principales metodologías de análisis de datos para la toma de decisiones en los negocios*

## **Agenda de la sesión 03:**

- *Tema 01: Repaso de la sesión 02*
- *Tema 02: Estandarización y Normalización de Datos*
- *Tema 03: Estimación puntual y por intervalos*
- *Tema 04: Correlación y Regresión*
- *Tema 05: Práctica en Python*



# TEMA 01: REPASO DE LA SESIÓN 02



# Proceso del análisis exploratorio de datos



# TEMA 02: ESTANDARIZACIÓN Y NORMALIZACIÓN DE DATOS



## Ley de los Grandes Números

Si se obtiene una muestra aleatoria de una población que obedece a cualquier modelo probabilístico, discreto o continuo, entonces si la muestra es suficientemente grande, el promedio muestral se aproxima al promedio poblacional.

La ley de los grandes números nos indica que, si se toman muchas observaciones, a la larga los errores tienden a compensarse.





# Ley de los Grandes Números

## Concepto



*“un promedio de muchas mediciones es más preciso que una sola medición”*

Formalmente:  $X_1, X_2, \dots$  son variables aleatorias (i.i.d) con igual media y varianza

$$\overline{X_n} = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{1}{n} \sum X_i$$

Entonces podemos saber que  $\overline{X_n}$  converge en probabilidad a la media de  $X$

Implica que el histograma converge a la función pdf




# Estandarización de Datos

Transformación que expresa la variable en términos de la media (promedio) y la desviación estándar (medida de variación).

$$z = (X - \mu) / \sigma$$

Para crear los números aleatorios en base a la distribución normal, usaremos el paquete NumPy.



## •¿Cuándo usarlo?:

- Cuando los datos tienen una distribución aproximadamente normal.
- Cuando trabajas con algoritmos que **suponen normalidad en los datos**, como **regresión lineal, regresión logística, SVM, PCA y redes neuronales profundas**.



## Normalización de Datos

La normalización transforma los valores para que estén dentro de un rango específico, típicamente  $[0,1]$  o  $[-1,1]$ . La fórmula es:

$$X_{\text{norm}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

### ¿Cuándo usarlo?:

- Cuando los datos no siguen una distribución normal.
- Cuando los valores tienen diferentes escalas y quieres llevarlos a un mismo rango (ejemplo: precios en miles y edades en años).
- Algoritmos sensibles a la escala de datos como **KNN, redes neuronales y SVM con kernel basado en distancia**.



# Normalidad de Datos

La distribución normal es una distribución de probabilidad que es simétrica y tiene forma de campana.

En una distribución normal:

- La media, la mediana y la moda son iguales.
- La curva es simétrica alrededor de la media.
- Aproximadamente el 68% de los datos se encuentran dentro de un desvío estándar de la media.



# Distribución Normal

Conocida como la distribución gaussiana, es la distribución continua de uso más común en la estadística, debido a que la inferencia estadística clásica se soporta mucho sobre ella.


$$y = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$\mu$  = Mean

$\sigma$  = Standard Deviation

$\pi \approx 3.14159 \dots$

$e \approx 2.71828 \dots$



# TALLER: APLICACIÓN DE EDA Y PREPARACIÓN PARA REGRESIÓN LINEAL PARA DETERMINAR SALARIOS:



Descarguen el notebook colab para ejecutarlo en clase



# TEMA 03: ESTIMACIÓN



## Estimación: Concepto

**Proceso de utilizar información de una muestra para extraer conclusiones acerca de toda la población**

Se utiliza la información para estimar un valor





## Tipos de Estimación

**PUNTUAL:** Se obtiene un único número al que se le puede asignar un punto de la recta

**POR INTERVALOS:** Se obtienen dos puntos que representan un límite inferior y superior ( $li$ ,  $ls$ )



## Estimación: Propiedades

- No tener sesgos (Término asociado al error)
- Poca variabilidad de una muestra a otra



# En una Estimación de debe considerar...

## ***Un intervalo***

*Espacio que tiene una cierta probabilidad de contener el verdadero valor del parámetro desconocido*

## ***Una medida de confianza***

$$\text{Coeficiente de confianza} = 1 - \alpha$$

$$\text{Nivel de confianza} = 100 * (1 - \alpha) \%$$



# Intervalos de Confianza

## Concepto

Debido a que la estadística frecuentista trata la estimación de parámetros como una estimación puntual, no tiene una aproximación inmediata al concepto de incertidumbre en la estimación.

Como solución a esto surge el concepto de intervalo de confianza. Este concepto está atado a la variabilidad ( $\sigma$ -desviación estándar) de nuestros datos muestrales y el nivel de confianza ( $\alpha$ ) que queremos tener.

$$\text{Inter. Confianza} = \left( \mu - t_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \mu + t_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right)$$

El intervalo de confianza resultante es:



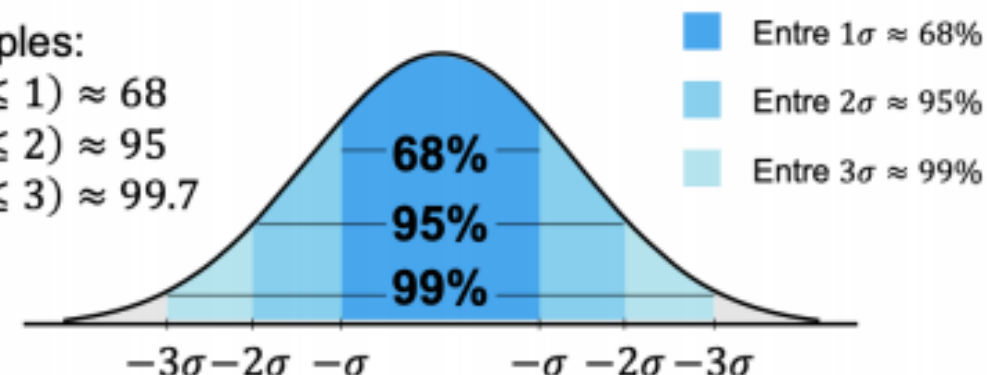
La desviación estándar  $\sigma$  es usada como una medida de probabilidad

Reglas simples:

$$P(-1 \leq Z \leq 1) \approx 68$$

$$P(-2 \leq Z \leq 2) \approx 95$$

$$P(-3 \leq Z \leq 3) \approx 99.7$$



[illegible]

## Intervalos de Confianza

- Se pueden crear para cualquier parámetro de la población.

### EJEMPLOS

Media: tiempo medio de recuperación

Proporción: de niños que sufren apendicitis

Desviación estándar: del error de medida de un aparato médico



## Intervalos de Confianza para la Media

Diagram illustrating the components of a 95% Confidence Interval (IC 95%) for the population mean ( $\mu$ ).

The formula is:

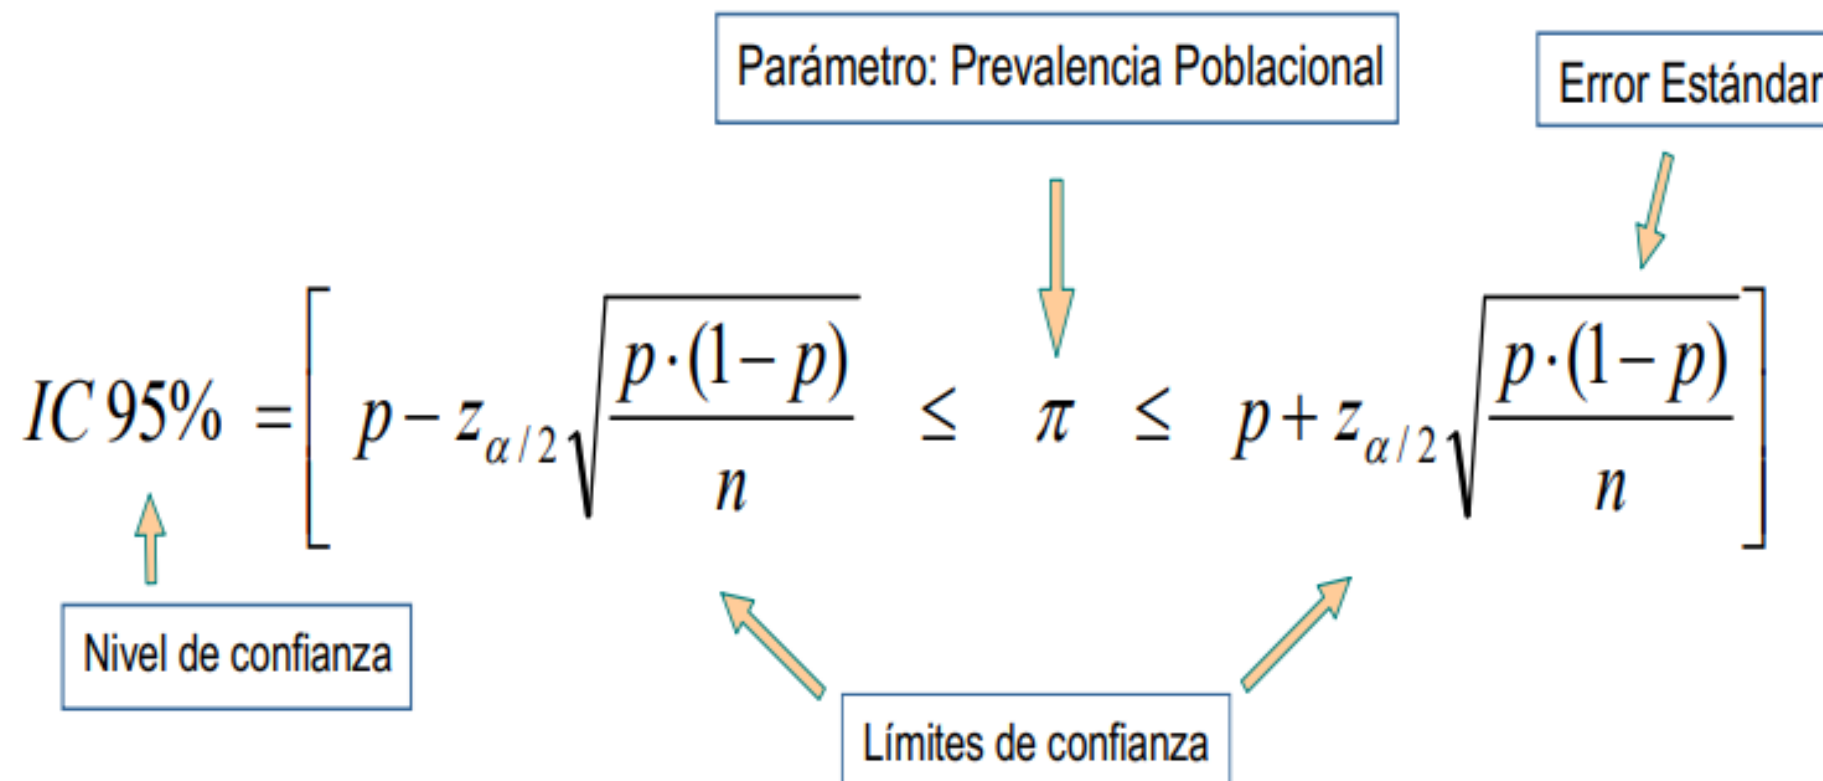
$$IC\ 95\% = \left[ \bar{x} - t_{n-1} \frac{s_{n-1}}{\sqrt{n}} \leq \mu \leq \bar{x} + t_{n-1} \frac{s_{n-1}}{\sqrt{n}} \right]$$

Annotations and components:

- Factor relacionado con la confianza** (Factor related to confidence): Points to the  $t_{n-1}$  term in the formula.
- Parámetro: Media Poblacional** (Parameter: Population Mean): Points to the  $\mu$  in the formula.
- Error Estándar** (Standard Error): Points to the  $\frac{s_{n-1}}{\sqrt{n}}$  term in the formula.
- Estimo** (Estimate): Points to the  $\bar{x}$  term in the formula.
- Nivel de confianza** (Confidence level): Points to the  $IC\ 95\%$  label.
- Límites de confianza** (Confidence limits): Points to the brackets of the interval.



## Intervalos de Confianza para Proporciones



$$IC\ 95\% = \left[ p - z_{\alpha/2} \sqrt{\frac{p \cdot (1-p)}{n}} \leq \pi \leq p + z_{\alpha/2} \sqrt{\frac{p \cdot (1-p)}{n}} \right]$$

Labels and their corresponding parts in the formula:

- Nivel de confianza** points to **IC 95%**.
- Parámetro: Prevalencia Poblacional** points to  $\pi$ .
- Error Estándar** points to the standard error term  $\sqrt{\frac{p \cdot (1-p)}{n}}$ .
- Límites de confianza** points to the entire confidence interval structure.






# TEMA 04: CORRELACIÓN Y REGRESIÓN




# Regresión y Correlación

La regresión y la correlación son dos técnicas estrechamente relacionadas y comprenden una forma de estimación



Correlación


vs




Regresión




# Tipos de Correlación




VARIABLES NO CORRELACIONADAS ( $r=0$ )





CORRELACIÓN LINEAL NEGATIVA ( $r=-1$ )



CORRELACIÓN NO LINEAL ( $r=0$ )




CORRELACIÓN LINEAL POSITIVA ( $r=+1$ )



## Correlación lineal: Consideraciones

- La correlación cuantifica cuan relacionadas están dos variables
- El cálculo de la correlación entre dos variables es independiente del orden o asignación de cada variable a XX e YY, mide únicamente la relación entre ambas sin considerar dependencias.
- A nivel experimental, la correlación se suele emplear cuando ninguna de las variables se ha controlado, simplemente se han medido ambas y se desea saber si están relacionadas

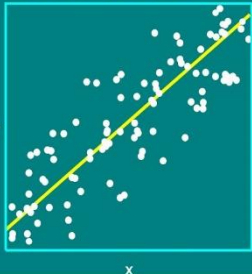


# Interpretación del Coeficiente de Correlación

**Coeficiente de Correlación**

$$\rho = \frac{S_{xy}}{S_x S_y}$$

ESTADÍSTICA



| Coeficiente       | Interpretación       |
|-------------------|----------------------|
| $r = 1$           | Correlación perfecta |
| $0.80 < r < 1$    | Muy alta             |
| $0.60 < r < 0.80$ | Alta                 |
| $0.40 < r < 0.60$ | Moderada             |
| $0.20 < r < 0.40$ | Baja                 |
| $0 < r < 0.20$    | Muy baja             |
| $r = 0$           | Nula                 |



## Coeficientes de Correlación:

### Coeficiente de correlación de Pearson

Tiene el objetivo de explicar la asociación que existen entre variables cuantitativas

$$\rho_{X,Y} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y} = \frac{E[(X - \mu_X)(Y - \mu_Y)]}{\sigma_X \sigma_Y}$$

- $\sigma_{xy}$  es la covarianza de (X,Y)
- $\sigma_x$  es la desviación estándar de la variable X
- $\sigma_y$  es la desviación estándar de la variable Y

¿Cuál uso?

Pearson → Normalidad

Spearman → No Normalidad

Kendall → No Normalidad\*

# Regresión Lineal


El análisis de regresión lineal múltiple es el primer modelo en el cuál pensar para predecir una variable en función de otra o ver pesos e impacto, no es efectivo en todos los casos, pero si es una propuesta a evaluar casi siempre. Los coeficientes de cada aspecto nos darán su importancia en la satisfacción general

Ecuación de Regresión


$$y_i = \alpha + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$$

Diagram illustrating the components of the regression equation:

- $y_i$ : Variable Dependiente (Dependent Variable)
- $\alpha$ : Coeficiente que suple aspectos no medidos (Coefficient that replaces unmeasured aspects)
- $\beta_1$  and  $\beta_2$ : Coeficientes de cada aspecto medido (Coefficients of each measured aspect)
- $\varepsilon_i$ : Error aleatorio en la predicción del modelo (Random error in the model prediction)



# Regresión: Importancia de los errores





## Coeficiente de Determinación R2

$$r^2 = \frac{\sum (\hat{y}_i - \bar{y})^2}{\sum (y_i - \bar{y})^2} = \frac{SCR}{SC_{tot}}$$

El coeficiente de determinación puede interpretarse como la **proporción de variabilidad de Y que es explicada por X**. Mide la proximidad de la recta ajustada a los valores observados de Y.

- **R2 = 0 → El modelo no explica nada. X no puede explicar Y.**
- **R2 cerca a 1 → El modelo es apropiado y X explica a Y.**
- **R2 cerca a 0 → El modelo es débil o X no explica del todo a Y.**



# Condiciones para la Regresión Lineal

- **Multicolinealidad (No colinealidad):** no debe haber relación lineal entre los predictores.
- **Relación Lineal entre los predictores numéricos y la variable respuesta:** debe existir una relación lineal entre la variable respuesta “Y” y cada uno de los predictores sin afectar al resto.
- **Distribución normal de la variable respuesta:** debe tener una distribución normal bajo test de hipótesis de normalidad y gráficas como histogramas.
- **Homocedasticidad (Varianza constante de la variable respuesta):** se grafican los residuos para identificar si la variable respuesta es constante en todo el rango de los predictores.
- **Independencia (No autocorrelación):** principalmente cuando se trabaja con series de tiempo, los valores de cada observación deben ser independientes de los otros.
- **Valores Atípicos:** identificarlos a través de los residuos y excluirllos.
- **Tamaño de la muestra:** usar la regla práctica, por cada variable predictora se debe tener como mínimo 20 casos.





**Intentar entender al  
otro significa destruir  
los clichés que lo rodean,  
sin negar ni borrar su  
alteridad.**

**Umberto Eco**



# ¡Gracias... Totales!

**Docente: Nilton Yanac**  
**Enero, 2026**

